

UNIVERSITÉ DU QUÉBEC À MONTRÉAL

OUTILS DE CLASSIFICATION TAXONOMIQUE BASÉS SUR DES RÉSEAUX NEURONAUX POUR ANALYSE DE  
DONNÉES MÉTAGÉNOMIQUES

MÉMOIRE

PRÉSENTÉ

COMME EXIGENCE PARTIELLE

DE LA MAÎTRISE EN INFORMATIQUE

PAR

VINCENT THERRIEN

MAI 2026

## RÉSUMÉ

Le séquençage d'ADN rapide rend possible de nouvelles applications en biologie et en médecine. Néanmoins, l'analyse d'un volume de plus en plus grand de données génomiques requiert des ressources informatiques et un temps de calcul massifs, d'où l'importance de développer des outils d'analyse efficaces.

La métagénomique étudie le matériel génétique prélevé dans les microbiomes, des communautés de microorganismes qui vivent dans des habitats très variés comme le sol, l'eau, le système digestif humain et d'autres environnements. Une meilleure compréhension des microbiomes est nécessaire pour améliorer notre capacité à les caractériser, ce qui aiderait à détecter les pathogènes plus efficacement ou mieux caractériser les sols en agriculture, par exemple. Une méthode répandue pour analyser des métagénomes consiste à comparer des séquences d'ADN prélevées dans un environnement avec des bases de données contenant des génomes de référence. Cette approche est toutefois lente et limitée par la qualité des bases de données. Une technique plus récente et plus flexible consiste à entraîner des réseaux neuronaux pour identifier les espèces présentes dans un métagénome, mais elle requiert un temps d'entraînement important et comporte des difficultés en lien avec l'interprétation des résultats.

Ce mémoire présente de nouvelles techniques de classification taxonomique des séquences d'ADN métagénomique, ce qui consiste à catégoriser les organismes dans des groupes génétiquement apparentés. Les techniques sont basées sur le modèle Mamba, un modèle à espace d'états, ainsi que des variantes modifiées par un traitement parallèle en flux (Mamba-Dual), un pré-traitement par CNN (Mamba-CNN), et une combinaison des deux améliorations (Mamba-Dual-CNN). Sur des ensembles de séquences d'ADN génétiquement diversifiées, Mamba-Dual-CNN classifie les données avec une précision moyenne de 89.97% ce qui se compare favorablement à un transformateur de taille similaire 72.46%, le modèle BERTax 86.88% et les outils MMSeqs 2 (88.20%) ainsi que Kraken 2 (75.51%). La durée d'entraînement des modèles à espace d'états testés est outre moins longue qu'un transformateur de taille similaire, avec 0.164s pour un pas avec Mamba-Dual-CNN contre 0.188s pour le transformateur.